Команда «Синергия»

MedOperatorAI

Голосовой ассистент регистратуры поликлиники

Хакатон «Точка сборки» · кейс № 2 «Голосовой ассистент для записи в клинику» · DBI · продуктовый бриф

> **Главный принцип — ноль ошибочных записей.** Ассистент лучше передаст звонок человеку, чем запишет не того пациента, не к тому врачу или не на то время.

Вопрос 1	Вопрос 2	Вопрос 3	Вопрос 4	Вопрос 5
Задача бизнеса и пользователь	Требования и ограничения кейса	Основной сценарий, прототип и архитектура	Ценность для пользователя и бизнеса	Метрики успеха

Живой прототип звонка → savin-alex.github.io/medoperator-concept

ВОПРОС 1

Какую задачу бизнеса мы решаем и кто наш пользователь

Телефон регистратуры — узкое место поликлиники: 85 врачей, 120 000 прикреплённых, 12 регистраторов в две смены, 1 200–1 500 визитов в сутки. Регистратор одновременно ведёт очередь у окна и отвечает на звонки.

24,9%

звонков в часы пик остаются без ответа

наш расчёт по журналу 17 772 звонков · в задании 30–40%

13,1%

неявок на приём; потери до 40–60 тыс. ₽ в день

наш расчёт по 35 470 приёмам · в задании 18–25%

70,6%

звонков типовые: запись или справка

наш расчёт · в задании около 60%

Пациент

Звонит, чтобы записаться, перенести или отменить приём, узнать расписание и режим работы. Часто звонит родитель за ребёнка.

Регистратор и старший администратор

Получают только сложные звонки: жалобы, медицинские и нестандартные вопросы. Карточка перевода уже содержит суть обращения.

Администратор и руководство

Видят звонки, итоги и ошибки. Отвечают за пропущенные звонки, неявки и нагрузку регистратуры.

ВОПРОС 2

Какие требования и ограничения кейса мы учитываем

Канал

- Голос по IP/SIP, входящие и исходящие звонки
- Естественная речь, без «нажмите 1»
- Дополняет IVR. Клавиша «0» — всегда к человеку

Границы ассистента

- Сам решает только типовые сценарии
- Жалобы, острая боль, медицинские и нестандартные вопросы → человек
- Нет диагнозов, лекарств и оценки симптомов

Стенд «Регистратура»

- API с токеном команды, 10 запросов в минуту
- Нет графика и проверки занятости
- Три статуса записи, время GMT+4

Расписание

- Файл Excel кейса: 85 врачей, 136 973 слота на 25.06–31.12.2026
- Предлагаем слоты на 14 дней вперёд, не позже чем за 30 мин до начала

152-ФЗ и данные

- Распознавание речи и LLM работают локально
- В стенде только вымышленные пациенты
- Запись разговора — с предупреждением и правом отказа

Качество

- Ноль ошибок в записи — главный приоритет
- Разговор проще и быстрее, чем с оператором: запись ≤ 2,5 мин
- 17 правил перевода из регламента поликлиники (R01–R17)

Источники: задание кейса, регламент регистратуры РГ-ТЕЛ-01, OpenAPI стенда

ВОПРОС 3 · СЦЕНАРИЙ

Как устроен основной сценарий

Входящий звонок

1. Представляется виртуальным помощником
2. Пациент говорит своими словами
3. Понимает цель: запись, перенос, отмена, статус, справка
4. Пациент называет фамилию, имя и дату рождения
5. Предлагает до трёх свободных вариантов
6. Зачитывает сводку, пациент явно говорит «да»
7. Сервер делает запись в стенде и сообщает итог

Напоминание накануне

- Звонок за рабочий день до визита, 10:00–19:00
- Не больше двух попыток через 2 часа
- Пациент подтверждает, переносит или отменяет визит
- Постороннему и автоответчику — без данных записи

Перевод на человека

- Угроза жизни: сначала «звоните 103 или 112», затем перевод до 20 с
- Просьба или «0»: перевод сразу
- Жалоба → старший администратор
- Дважды не понял → предложить человека
- Оператор получает карточку с сутью звонка

Ноль ошибок

- Полная сводка и явное «да»
- Запись делает сервер, а не модель
- Слот резервируется атомарно
- Запрос в стенд уходит один раз
- Потерянный ответ сверяется, без дублей

Прототип звонка и архитектура — на следующих слайдах

ВОПРОС 3 · ПРОТОТИП ЗВОНКА

Звонок изнутри: запросы к LLM и компонентам

ПАЦИЕНТ ГОВОРИТ	ЧТО ПРОИСХОДИТ ВНУТРИ
«Запишите меня к терапевту на завтра, после обеда»	`Whisper` речь → текст. `LLM` срочность: not_detected и намерение: unrelated, параллельно, до 1,2 с. `LLM` диалог: `resolve_need`(«терапевт»), `parse_datetime`(«завтра после обеда»)
«Петрова Анна, пятое мая девяностого года»	`Сервер` приводит имя к форме стенда. `Стенд` `GET /clients` → не найден, `POST /clients` → 201, client_id 57. `LLM` `find_slots` → 3 свободных слота терапевта из Excel-расписания
«Давайте в четырнадцать двадцать»	`LLM` `select_and_prepare_booking`(вариант 2) → сводка, записи ещё нет. `Сервер` резервирует слот 14:20, сводку читает шаблон сервера
«Да, верно»	`LLM` намерение: affirm, проверка действия: «разрешает». `Сервер` согласие принято, операция в журнале. `Стенд` `POST /visits` → 201, id 1042. `Сервер` сверяет ответ

Запись № 1042 Запланирована

Пациент	Петрова Анна · 05.05.1990
Врач	Малахова Оксана Григорьевна · терапевт · каб. 106
Приём	15.10.2026 14:20 (GMT+4)

Каждая реплика: `Asterisk` → `Whisper` → `LLM` → `Сервер` → `Piper` → пациент.

Разговор потратил 3 запроса к стенду из 10 в минуту. Справочник врачей взят из кэша.

Анимированный прототип — весь звонок по шагам, с каждым вызовом компонентов:

`savin-alex.github.io/medoperator-concept`

Иллюстрация на вымышленных данных · модели: faster-whisper small, Qwen3-4B в llama.cpp, Piper

ВОПРОС 3 · АРХИТЕКТУРА

Полная архитектура: всё работает в нашем контуре

Пациент

Софтфон Linphone

Звонок по SIP. Для теста хватает двух софтфонов: «пациент» и «оператор»

→

Asterisk 22 LTS

Телефония

PJSIP, очередь операторов, клавиша «0». Управление — ARI, звук — WebSocket 16 кГц

→

Медиашлюз

Фраза и перебивание

Собирает фразу пациента. Если пациент перебил, останавливает речь бота (FLUSH_MEDIA)

↓

Whisper

Распознавание речи

faster-whisper small, CPU, int8, beam 5, русский язык. Звук не уходит наружу

←

LLM-проверки

Срочность и намерение

llama.cpp на 127.0.0.1, temperature 0, строгая JSON-схема. Параллельно, до 1,2 с. Для «да» — проверка действия

←

LLM-диалог

Разговор и инструменты

Qwen3-4B, вызов функций по одной: врач, дата, слоты, подготовка записи. Ход до 12 с. Записать сама не может

↓

Сервер операций

Решает, выполнять ли действие

Права, сводка и согласие, правила перевода R01–R17, календарь и резервы, журнал операций

→

Адаптер стенда

Лимит и сверка

Общий лимит 10 запросов в минуту, кэш врачей, сверка неизвестного исхода

→

Стенд

«Регистратура»

Пациенты, врачи, записи. Жюри видит результат в панели стенда

Обратный путь шаблон сервера или текст модели → одна очередь речи → синтез Piper → медиашлюз → Asterisk → пациент

· архив звонков и панель администратора — отдельный контур

Открытый стек: Asterisk, faster-whisper, Qwen3, llama.cpp, Piper, Python 3.13, SQLite

ВОПРОС 3 · МОДЕЛИ

Модели: что работает сейчас и что мы сравниваем

РОЛЬ	СЕЙЧАС · ЛОКАЛЬНО	ДРУГИЕ ЛОКАЛЬНЫЕ МОДЕЛИ	ОБЛАКО · 152-ФЗ
LLM **Проверки и диалог**	Qwen3-4B (Q4_K_M) в llama.cpp	Qwen3-8B и Qwen3-14B · YandexGPT 5 Lite 8B · T-lite и T-pro (Т-Банк)	YandexGPT (Yandex AI Studio) · модели Cloud.ru Foundation Models
ASR **Распознавание речи**	faster-whisper small, int8	Whisper large-v3-turbo · GigaAM (Сбер) · T-one (T-Банк, для телефонии) · Vosk	Yandex SpeechKit, потоковое распознавание · SaluteSpeech
TTS **Синтез речи**	Piper	Piper, голос «Ирина» · Silero · Qwen3-TTS	Yandex SpeechKit · SaluteSpeech

Как сравниваем

- Один корпус: 20 сценариев сравнения и 16 контрольных диалогов регламента
- Одни лимиты: проверки за 1,2 с, ход до 12 с
- Отдельно считаем качество, задержку и стоимость
- Главный критерий — ноль ошибочных действий

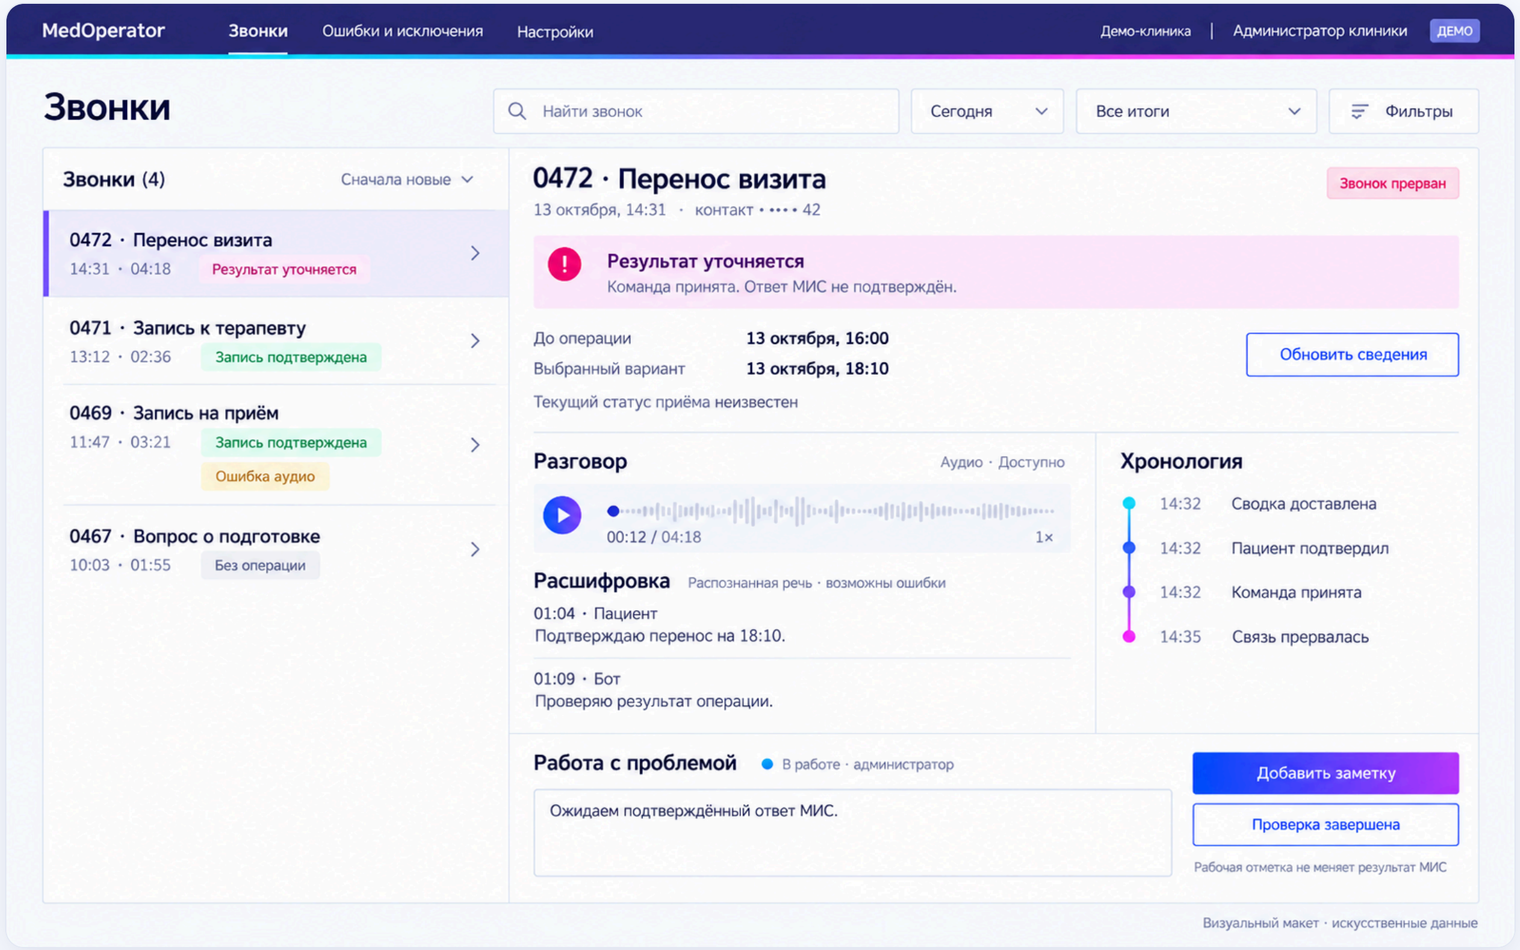
Правила для облака

- Реальные данные пациентов — только в сервисе с аттестатом УЗ-1 и договором поручения обработки ПДн
- Сравнение идёт на синтетическом корпусе: условия одинаковы для всех моделей
- Облако — опция: при сбое работает локальная модель
- У каждого сервиса свой маршрут, ключи вне Git

Модель меняется в конфигурации, сценарий и проверки остаются прежними

ВОПРОС 3 · ПРОТОТИП ИНТЕРФЕЙСА

Панель администратора: звонки, итоги, ошибки



Что видит администратор

- Список звонков с итогом каждого
- Карточку звонка: аудио, расшифровку, хронологию
- Ошибки и незавершённые операции
- Рабочие отметки и заметки

Пример на макете: связь прервалась после подтверждения. Панель честно пишет «Результат уточняется». Повторной записи нет.

Утверждённый макет, искусственные данные. Вход, список звонков, карточка, аудио и текст уже сделаны в коде.

Голосовой интерфейс пациента — прототип звонка на слайде 5

ВОПРОС 4

Какую ценность получают пользователь и бизнес

Пациент

- Дозванивается сразу, даже в часы пик
- Записывается своими словами, без меню, за ≤ 2,5 мин. Оператор сейчас тратит 166,6 с на звонок с записью
- Получает напоминание накануне и переносит визит одним звонком
- Со сложным вопросом сразу попадает к человеку и не пересказывает всё заново

13–24

тыс. ₽ в день сохраняет снижение неявок на 30–40%

оценка: 200 записей × 1 200 ₽ × 18–25%

≈ 3 ч

разговоров в день освобождается у регистраторов

оценка: 5 ч типовых звонков в день по журналу × 60%

Поликлиника

- Меньше пропущенных звонков: ассистент рассчитан на 10 разговоров одновременно. Пик журнала — 9
- Регистраторы работают с людьми у окна и со сложными случаями
- Цель — ноль ошибочных записей и дублей: каждая операция сверяется со стендом
- Данные пациентов обрабатываются локально

Денежные цифры — сценарная оценка по данным кейса, а не измеренный эффект

ВОПРОС 5

По каким метрикам мы поймём, что решение работает

Метрики кейса

МЕТРИКА	ЦЕЛЬ	КАК СЧИТАЕМ
Пропущенные звонки	**≤ 15%**	все входящие в окне замера
Неявки	**≤ 12%**	состоявшиеся и неявки
Звонки без человека	**≥ 60%**	коды итога звонка
Ожидание ответа	**≤ 30 с**	до ответа по сути
Оценка пациента	**≥ 4 из 5**	добровольный опрос после звонка

Метрики качества решения

МЕТРИКА	ЦЕЛЬ	КАК СЧИТАЕМ
Ошибочные записи	**0**	сверка операций со стендом
Пропущенные красные флаги	**0**	размеченные тестовые звонки
Обоснованные переводы	**≥ 90%**	разметка каждого перевода
Длительность записи	**≤ 150 с**	все начатые сценарии записи
Ответ ассистента	**≤ 1,5 с**	медиана; 95% — до 2,5 с

Правила отчёта: в знаменатель входят все попытки пустая выборка — «не измерено», а не ноль тестовые звонки не выдаём за эффект в клинике

Источник целей: задание кейса и регламент РГ-ТЕЛ-01, раздел 9